Tarea Complementaria

Problema 1:

En reconocimiento de patrones biomédicos, no todas las muestras de un dataset tienen la misma confiabilidad. Por ejemplo, algunas mediciones clínicas pueden provenir de equipos más precisos que otros, o haber sido adquiridas en condiciones con distinto nivel de ruido.

Supongamos que tenemos un conjunto de datos de pacientes

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}$$

donde:

- x_i es el vector de características de la muestra i,
- y_i es una variable clínica continua asociada a esa muestra,
- $t_i > 0$ es un peso escalar que refleja la importancia o confiabilidad de la muestra i.

Se desea ajustar un modelo de regresión lineal mediante la siguiente función de error ponderada:

$$E_{\text{pond}}(w) = \frac{1}{2} \sum_{i=1}^{N} t_i \left(w^T \phi(x_i) - y_i\right)^2$$

donde $\phi(x_i)$ representa el vector de entrada de la muestra i, posiblemente transformado mediante funciones base.

Además, considere la matriz diagonal de pesos

$$T = \text{diag}(t_1, t_2, \ldots, t_N)$$

Se pide

a) Derive la expresión analítica del vector de pesos w^*que minimiza la función de error $E_{\text{pond}}(w)$. Exprese el resultado final en forma matricial.

b) Interprete el significado del factor $t_i$en los siguientes escenarios clínicos:

- cuando t_i refleja la confiabilidad de la medición, por ejemplo, si

$$t_i = \frac{1}{\sigma_i^2},$$

donde σ_i^2 es la varianza del ruido presente en la medición de cada paciente;

- cuando existen registros duplicados o múltiples observaciones muy similares de un mismo paciente dentro del dataset.

c) Explique brevemente por qué este problema corresponde a un caso de aprendizaje supervisado de regresión dentro del curso.

Observación

Para el desarrollo, puede partir de la forma matricial:

$$E_{\text{pond}}(w) = \frac{1}{2}(\Phi w - y)^T T(\Phi w - y)$$

donde Φ es la matriz de diseño y y es el vector de salidas observadas.

a.) Mínimo de su error:

pendiente $= 0 \rightarrow \frac{dE}{dw} = 0 = \Phi^T T(\Phi w - y)$

$$\Phi^T T \Phi w = \Phi^T T y$$

$$\downarrow$$

$$w^* = \frac{\Phi^T T y}{\Phi^T T \Phi}$$

b. ↳ Confiabilidad de medición

t_i: confiabilidad
σ_i^2: varianza del ruido

} Son inversamente proporcionales

↓ varianza ⟷ ↑ peso de confiabilidad

↓

Se confía más en datos del paciente con menos variación de ruido (es decir, en condiciones controladas)

↳ Datos duplicados

Múltiples registros duplicados → Aumenta su peso efectivo

Tienen mayor influencia en el resultado final del modelo

c) Supervisado, ya que tiene:

- x_i: características del paciente (inputs)
- y_i: valor real (salida) ← Si no fuera supervisado, no tendría salida(s), ya que el modelo busca patrones por sí solo.

Además de que el objetivo es predecir una variable continua utilizando x_i y y_i.

Problema 2:

En reconocimiento de patrones biomédicos, un clasificador lineal divide el espacio de características en regiones asociadas a distintas clases mediante un hiperplano:

$$w^T x + b = 0$$

Suponga que se tiene un sistema de clasificación binaria para pacientes descritos por dos características biomédicas x_1 y x_2.

Se sabe que la frontera de decisión lineal del clasificador intercepta al eje $x_1$en el valor 2 y al eje $x_2$en el valor 5.

Se pide:

a) Escriba la forma general del modelo clasificador lineal con término de sesgo (bias). Indique cuántos parámetros necesita dado que los datos son bidimensionales.

b) Calcule un conjunto posible de coeficientes w_1, w_2 y b que definan esa frontera de decisión.

c) Escriba la regla de decisión binaria asociada al clasificador, indicando cómo se asigna una nueva muestra a una u otra clase según el signo de:

$$w_1 x_1 + w_2 x_2 + b$$

Observación: Recuerde que la frontera cruza el eje x_1 cuando $x_2 = 0$, y cruza el eje x_2 cuando $x_1 = 0$.

a) Para este caso bidimensional (2 características: x_1 y x_2):

$$y = w_1 x_1 + w_2 x_2 + b$$

Numero de parámetros: w_1, w_2 y b (3 parámetros)

b)

- $x_1 = 2$ punto $(2;0)$
- $x_2 = 5$ punto $(0;5)$

Ecuacion de la recta: $y = mx + K$

$$\frac{x_1}{2} + \frac{x_2}{5} = 1$$

ya que se cruzan

$$5x_1 + 2x_2 = 10$$

$$5x_1 + 2x_2 - 10 = 0$$

$$\boxed{w_1 = 5 \; ; \; w_2 = 2 \; ; \; b = -10}$$

c)

$$y = w_1 x_1 + w_2 x_2 + b$$

$$y = 5x_1 + 2x_2 - 10$$

Por lo que

casos: $y \geq 0$: Clase 1

$y < 0$: Clase 0