

Tarea Complementaria

Problema 1: PCA y SVD aplicado a señales biomédicas

En sistemas de monitoreo clínico es común registrar múltiples señales fisiológicas simultáneamente: frecuencia cardíaca, SpO_2 , presión arterial, temperatura, entre otras. Esto genera datos de alta dimensión, donde algunas variables pueden contener información repetida o correlacionada.

La Descomposición en Valores Singulares (SVD) permite encontrar una representación compacta de esos datos en un espacio de menor dimensión, idea directamente relacionada con PCA.

Considere la matriz X , donde cada fila representa un paciente y cada columna una señal fisiológica registrada durante una prueba de esfuerzo:

$$X = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 3 & 3 & 0 & 0 \\ 4 & 4 & 0 & 0 \\ 0 & 0 & 4 & 4 \\ 0 & 0 & 5 & 5 \\ 0 & 0 & 2 & 2 \end{bmatrix} \quad \Rightarrow X(\text{paciente}; \text{señal})$$

Los pacientes 1–3 presentan un patrón predominante en las señales 1 y 2, mientras que los pacientes 4–6 presentan un patrón predominante en las señales 3 y 4.

Se sabe que la SVD reducida de X permite representar los datos usando dos componentes principales.

Se pide:

- Explique con sus propias palabras qué representa aplicar PCA/SVD a este conjunto de señales biomédicas.
- ¿Por qué este dataset presenta redundancia en sus variables? Relacione su respuesta con las columnas de X .
- Suponga que los dos valores singulares no nulos son:

$$\sigma_1 = 7.35, \quad \sigma_2 = 5.10$$

La varianza explicada por cada componente es proporcional a σ_i^2 . Calcule el porcentaje de varianza explicado por cada componente principal.

- Llega un nuevo paciente, Lucía, con el siguiente perfil fisiológico:

$$x_{Lucia} = [3 \ 3 \ 0 \ 0]$$

Sin hacer una proyección numérica completa, indique con qué grupo de pacientes se asocia más Lucía en el espacio reducido: pacientes 1–3 o pacientes 4–6. Justifique.

- e) En el Challenge 5 se aplicó `StandardScaler` antes de PCA. Explique en qué casos es necesario estandarizar antes de aplicar PCA/SVD. ¿Qué problema podría surgir en un dataset biomédico real si se omite este paso?

Rpta:

- a) Aplicar PCA permite a este conjunto de señales biomédicas permite reducir la bidimensionalidad de los datos, encontrando patrones que resuman la info. más importante. Es decir, identifica las combinaciones de variables las cuales concentran la mayor variabilidad del dataset. para detectar patrones fisiológicos comunes.
- b) $\hookrightarrow$ Las señales 1 y 2 y también las señales 3 y 4 están correlacionados entre sí
Por lo que a pesar que las señales son diferentes, varias señales describen prácticamente el mismo comportamiento fisiológico.
 $\downarrow$
PCA detecta esa redundancia y la reemplaza por menos variables independientes
- c) $\sigma_1^2 = 7,35^2 = 54,02$
 $\sigma_2^2 = 5,10^2 = 26,01$ } suma = 80,03
Componente 1 = $\frac{54,02}{80,03} = 67,5\% \leftarrow$ Más importante
Componente 2 = $\frac{26,01}{80,03} = 32,5\%$
- d) Se asocia más con el grupo de pacientes 1–3, ya que presenta un patrón dominante entre las señales 1 y 2, como los pacientes 1–3
- e) Si no se estandariza, las variables con valores más grandes dominarán el cálculo de la varianza y PCA dará más importancia a esas señales, aunque no sean relevantes. y podría producir componentes sesgados y se perderían patrones fisiológicos importantes.

Problema 2. K-means, centroides y su interpretación biomédica

K-means es ampliamente utilizado en reconocimiento de patrones biomédicos para agrupar señales, pacientes o características sin etiquetas. Por ejemplo, puede emplearse para agrupar pacientes con perfiles cardiometabólicos similares o tumores con características morfológicas parecidas.

K-means busca dividir los datos en K grupos, minimizando la distancia de cada punto al centroide de su cluster.

La función objetivo de K-means es:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

donde:

- C_k es el conjunto de puntos asignados al cluster k ,
- μ_k es el centroide del cluster k .

Se pide:

- Explique con sus propias palabras qué significa minimizar J .
- ¿Qué representa el centroide μ_k en un problema biomédico? Dé un ejemplo.
- Explique por qué K-means puede ser sensible a la inicialización de los centroides.
- K-means garantiza encontrar el mínimo global de J ? Justifique.
- Explique cómo `KMeans(n_init=10)` ayuda a reducir el problema de la inicialización.
- En el Challenge 5 se aplicó K-means sobre el espacio PCA reducido del dataset Breast Cancer Wisconsin. Explique por qué puede tener sentido interpretar los centroides como perfiles morfológicos promedio de cada grupo tumoral.
- Mencione dos limitaciones de K-means en problemas biomédicos reales.

Rpta:

- Significa hacer que los puntos de cada cluster estén lo más cerca posible de su centroide.
- μ_k representa el perfil promedio de los datos pertenecientes a un cluster. En contextos de ingeniería biomédica, puede ser representativo del grupo.
- Porque los centroides iniciales determinan cómo comienzan a formarse los clusters. Si los centroides iniciales se colocan en posiciones poco adecuadas algunos grupos pueden quedar mal separados y producir resultados distintos.

d) No, ya que K-means solo garantiza converger a un mínimo local de la función objetivo

e) $n_{\text{-init}} = 10$.

K-means ejecuta 10 veces con distintas inicializaciones aleatorias de centroides, esto reduce la probabilidad de "quedarse atrapado" en un mínimo local erróneo y mejora la calidad del clustering

f) variables describen características y;

Cuando K-means se aplica sobre el espacio reducido por PCA:
cada cluster agrupa tumores con características similares y μ_k representa el perfil promedio de ese grupo tumoral.
Por ello, los centroides pueden interpretarse como patrones morfológicos típicos de distintos tipos de tumores.

g) Limitaciones:

1. Sensibilidad a outliers

2. Supone clusters esféricos